



Thynk Unlimited

IA NO HARDWARE

INTEGRAÇÃO DE MICROCONTROLADORES COM MODELOS DE IA NA NUVEM

Elaborado por: Erivelto Silva



AGENDA DE HOJE

◀ O que é IA, ML, DL, GenAI

◀ Setup

◀ Web Server + Dashboard + GenAI

◀ Como funcionam os LLMs (tokens)

◀ Utilizando GenAI no ESP32

◀ Big Providers e Open Source

◀ Controlando carga com GenAI

◀ IA no Edge vs Cloude

◀ Arquitetura IoT

◀ Aumentando contexto - Sensor

Inteligência Artificial



Sistemas que executam tarefas que tipicamente exigiriam inteligência humana – perceber, raciocinar, aprendizado, decisão.



Perceber

Reconhecer caras, transcrever voz, ler matriculas



Raciocinar

Diagnosticar, jogar xadrez, resolver problemas








Aprender

Melhorar com dados sem ser explicitamente programado


ARTIFICIAL INTELLIGENCE



Sistemas que executam tarefas que tipicamente exigiriam inteligência humana – perceber, raciocinar, aprendizado, decisão.



Tudo no seu lugar



IA

Campo amplo - tudo que parece inteligente

ML

Aprende padrões a partir de dados

DL

ML com redes neurais profundas

GenAI

DL que GERA conteúdo novo (texto, imagem, áudio)



Thynk Unlimited

IA/Software

Hardware/Actuação

Percepção

Sensores

Decisão

Mundo Físico

Aprendizagem

Visão

Motores

Entendimento da
linguagem

Sistemas de
suporte

Memória


ROBÓTICA

www.reallygreatsite.com

Aprender arduino é o inicio perfeito para entrar no mundo da robótica



ROBÓTICA



Os LLM mudaram tudo

LLM

A conceptual illustration of artificial intelligence. In the center, a glowing blue, wireframe brain is superimposed over a complex circuit board. The circuit board is divided into two main color zones: a warm orange-gold on the left and a cool blue on the right. Numerous small, square components are scattered across the board, connected by intricate lines. The brain itself is composed of a mesh of points and lines, giving it a digital, networked appearance. The letters 'LLM' are prominently displayed in white, bold font across the middle of the brain.

PORQUÊ IA GENERATIVA?

DISCRIMINATIVA (classica)

Classifica / decide entre opções existentes

- Esta foto é: cão ou gato?
- Este email é: spam ou não?
- Esta transacção é: fraude?
- Vou aprovar este crédito?
- Devo recomendar este produto: sim?

Output: rótulo / número

(escolhe entre o que já existe)


GENERATIVA (LLMs, GenAI)

GERA conteúdo novo que não existia antes

- Escreve um poema sobre Luanda
- Gera código Python para X
- Cria imagem de robô no deserto
- Resume este artigo em 3 frases

Output: texto, imagem, áudio, código


(produz algo novo, palavra a palavra)




CLAUDE
CODE



OPENCLAW



OpenClaw Local Architecture (Simplified)



Meta to cut one in 10 jobs after spending billions on AI

24 April 2026

Share 

Save 

 Add as preferred on Google

Kali Hays

Technology reporter

Microsoft and Meta announce large staff reductions as they spend big on AI

Meta said it would cut 10% of its employees while Microsoft will offer voluntary retirement to about 7% of workers

Article • Artificial Intelligence (AI)

Why Uber has Already Burned Through its AI Budget

By Diya Joseph

April 23, 2026 • 3 mins

As 40 profissões mais impactadas pela inteligência artificial, segundo estudo da Microsoft

Estudo considerou o mercado de trabalho americano. Carreiras que dependem de linguagem, computação, matemática ou tarefas repetitivas têm maior chance de serem impactadas por IA; trabalhos manuais ou físicos tendem a ser menos afetados.

What do Ukraine's robot soldiers mean for the future of warfare?

Remote-controlled weapons have been used for some time, but AI is now on the cusp of making battlefield decisions.

Listen (8 mins) Save Share Add Al Jazeera on Google



Ukraine's killer robots show how war is changing

Published: April 27, 2026 3:05pm SAST



A robot ran a half marathon faster than a human. Here's why folding laundry is still harder

A premapped course, a crew of handlers and a world-beating time: here's what this Beijing half marathon reveals about how far humanoid robots have come—and how far they haven't

BY DENI ELLIS BÉCHARD EDITED BY ERIC SULLIVAN



Amazon's little blue delivery robot is roaming around the Seattle suburbs

The autonomous bots are already on the road.

SHARE ADD ON GOOGLE



DEFENSE


Anthropic's Claude used by Pentagon in war with Iran, official confirms

BY FILIP TIMOTIJA - 03/24/26 5:39 PM ET

Link Email Facebook X Instagram



É possível que a humanidade
acabe assim?



“Se não pode vence-los, jun...”

CONCEITO-CHAVE: TOKENS

LLMs não processam letras nem palavras inteiras – processam tokens (pedaços de texto)

Exemplo: “Bom Dia, Angola!”

Bom

_dia

,

_Ang

ola!

5 tokens, cada bloco colorido = 1token



Regra prática em inglês

~ 1 token = 4 caracteres = 0.75 palavras

Tokens, entendendo a fundo



<https://tiktokenizer.vercel.app>

Acesse o endereço acima faça testes com a frase:

“Angola é um país grande e belo. Pela sua extensão, está acolhendo mais uma vez o Arduino day”

PORQUÊ PENSAR EM TOKENS



Custo

Pagamos por token. Pergunta longa + contexto + resposta = mais \$



Janela de contexto

Modelo tem limite (ex: 128K tokens).
Mais que isso: não 'cabe' na conversa



Performance

Mais tokens = mais tempo de resposta
e mais consumo de energia

 **Meta**
Llama 3.1

Human: What so te a lama use to write code?

Al llama: A LlamaPad, of course! 😊

Human: Now let's hear it in Ferichsh!


Al llama: Quel outil utilise une lama pur coder?
Un LlamaPad, bien sûr co!! 😊

DATA

DATA 2

DATA 2

Claude



ChatGPT



O motor da revolução moderna



OPEN SOURCE: SÓ TÚ PARA NOS LIVRAR

Modelos abertos

- Llama (Meta) 
- DeepSeek (China) 
- Mistral (França) 
- Qwen (Alibaba) 
- Phi (Microsoft) 
- Gemma (Google) 

Porque importa para Angola?

- **Soberania tecnologica**
 - Modelo corre nos nossos servidores - dados não saem
- **Sem dependência de tarifas externas**
 - Custo previsível - só paga o hardware
- **Liberdade de fine-tuning**
 - Adaptar para português / kimbundu / contexto local



EDGE

Modelo corre no próprio dispositivo

Vantagens:

- Latência ultra baixa (ms)
- Funciona sem internet
- Privacidade total
- Sem custos de API

Desvantagens:

- Modelos pequenos (capacidade limitada)
- Hardware com restrições serias



CLOUD

Modelo corre num data center remoto

Vantagens:

- Modelos enormes e capazes
- Actualizações automáticas
- Sem necessidade de hardware caro
- Acesso a multimodal (visão, áudio)

Desvantagens:

- Latência (rede + processamento)
- Custo por token + dependência da net



LIMITAÇÕES

Recurso	ESP32	Telemóvel topo	Servidor c/ GPU
RAM	520 KB	12 GB	640 GB+
CPU	240 MHz dual	3 GHz octa	AMD EPYC + GPU
Energia	100 mW	5 W	1000 W+
Modelo cabivel	TinyML (KB)	1-3B params (Q4)	GPT-4 (~1T params)

OPORTUNIDADES ESTÃO A CHEGAR



Automação do trabalho intelectual

- Codificar, escrever, analisar, projetar
- LLMs já substituem juniors em muitas tarefas
- Engineers viraram orquestradores de IA
- Saber prompt + arquitetura > saber syntax



Robótica humanoide acessível

- Tesla Optimus, Figure, Unitree - preços a cair
- LLMs são o cérebro
- Trabalho físico repetitivo: 10-15 anos
- Quem souber integrar tem oportunidade enorme

A FRONTEIRA DO AMANHÃ

Electrónica

Arduino, sensores, hardware


Software

APIs, web, cloud

IA

LLMs, prompts, agentes

Quem dominar a interseção será raro, e vai construir o futuro.




Agora: mãos à obra!

Vamos construir um chatbot que controla um dispositivo de verdade.

Arquitetura do que vamos construir

Arquitetura do Workshop

ESP32 como Edge + Backend → DeepSeek (Cloud AI) → Frontend (SPIFFS)



Fluxo de uma pergunta no chat:

- 1 User escreve
- 2 ESP32 monta prompt + estado
- 3 Chama DeepSeek (HTTPS)
- 4 Resposta volta com comando
- 5 ESP32 faz parsing
- 6 Se "LED_ON/OFF" -> aciona pino
- 7 Devolve texto ao chat do browser



Thynk Unlimited



THANK YOU.

Erivelto da Costa e Silva
eriveltoclenio@gmail.com